

Anchors : explications locales à haute précision

Du mécanisme théorique à une expérimentation contrôlée sur AnchorImage (Alibi Explain)

Fokouo Luciano


École Nationale Supérieure Polytechnique de Yaoundé
Master 2 Data Science

20 août 2026

Plan de la présentation

- 1 Introduction
- 2 Anchors
- 3 Expériences des auteurs
- 4 Limites et Alibi
- 5 AnchorImage
- 6 Limites, enseignements, perspectives

Où se situe Anchors dans mon exploration ?



Concrètement, « représentations structurées » recouvre

règles symboliques • concepts (**FCA**) • ontologies • knowledge graphs • systèmes experts •
raisonnement symbolique

Anchors se situe dans « explication compréhensible » : une étape de cette exploration, pas son terme.

Anchors (2018)


Ribeiro, Singh, Guestrin
AAAI-18

Rôle : article fondateur — mécanisme, formalisation, garanties de précision/couverture.

Alibi Explain (2021)

Klaise, Van Looveren, Vacanti, Coca
Journal of Machine Learning Research, vol. 22


Rôle : bibliothèque moderne — implémentation utilisée pour AnchorImage.



I — Anchors

Du problème de l'explication locale au mécanisme de recherche d'une règle

Expliquer une prédiction locale



« Pourquoi le modèle prédit-il y pour cette instance x ? »

Expliquer globalement

Comprendre f dans son ensemble — souvent hors de portée pour un modèle complexe

Expliquer localement

« Zoomer » autour de x : le comportement local est plus simple à décrire que le comportement global

LIME (Ribeiro et al., 2016) est l'une des méthodes d'explication locale les plus utilisées — point de départ de la discussion.

Pourquoi LIME ne suffit pas toujours



- 1 Précision non garantie
- 2 Région de validité (« coverage ») peu claire
- 3 Risque d'appliquer l'explication à une instance où elle ne vaut plus
- 4 Comportement local parfois non linéaire
- 5 Poids à interpréter/comparer mentalement



Figure 1: Sentiment predictions, LSTM

« not » influence positivement à gauche, négativement à droite : la couverture n'est pas claire — LIME n'est pas « mauvais », la critique porte précisément sur cette couverture non garantie.

L'idée d'Anchors, en une phrase

SI FICO score ≤ 649

ALORS prédiction = *Bad Loan*

« Si ces conditions restent vraies, le modèle conserve généralement la même prédiction. »

Precision

« Quand l'anchor s'applique, la prédiction reste-t-elle la même ? »

Coverage

« Sur quelle proportion des instances l'anchor s'applique-t-elle ? »

exemple réel, jeu de données *lending*

Règle et application

$$A(x) = 1$$

A est un ensemble de predicates; $A(x) = 1$ signifie que x vérifie toutes les conditions de A .

Précision

$$\text{prec}(A) = \mathbb{E}_{z \sim D(z|A)} [\mathbb{1}_{f(x)=f(z)}]$$

$\mathbb{1}_{f(x)=f(z)} = 1$ si $f(x) = f(z)$, 0 sinon — proportion de perturbations (respectant A) qui conservent la prédiction.


$$\text{prec}(A) \geq \tau$$

τ : seuil de précision souhaité

$$\text{cov}(A) = \mathbb{E}_{z \sim D}[A(z)]$$

proportion de D couverte par A

Comment construire une anchor ?




Parmi les anchors valides rencontrées, on préfère celle de plus grande coverage.

KL-LUCB : où échantillonner en priorité ?

Bandit	Anchors
Bras	Candidate A
Tirage	$z \sim D(z A)$
Reward	$\mathbb{I}_{f(x)=f(z)}$

reward = 1 : la perturbation conserve la prédiction

reward = 0 : la perturbation change la prédiction




A et B restent proches : on continue à les échantillonner. C est déjà nettement séparée.

KL-LUCB concentre les tirages sur les candidates les plus ambiguës, sans échantillonner inutilement les autres.


Beam Search : ne pas s'enfermer dans un seul choix

Greedy



Un choix intermédiaire décevant est irréversible.

Beam Search



B candidates conservées en parallèle à chaque étape.

$$\max \text{cov}(A) \text{ sous } \text{prec}(A) \geq \tau$$

L'algorithme, formalisé

```
1: function BEAMSEARCH( $f, x, \mathcal{D}, \tau$ )
2:   hyperparamètres :  $B$  (largeur du faisceau),  $\epsilon, \delta$ 
3:    $A^* \leftarrow \emptyset$ ;  $\mathcal{A}_0 \leftarrow \{\emptyset\}$ 
4:   repeat
5:      $\mathcal{A}_t \leftarrow \text{GENERATECANDS}(\mathcal{A}_{t-1}, \text{cov}(A^*))$ 
6:      $\mathcal{A}_t \leftarrow \text{B-BESTCAND}(\mathcal{A}_t, \mathcal{D}, B, \delta, \epsilon)$ 
7:     for  $A \in \mathcal{A}_t$  avec  $\text{prec}_{lb}(A) > \tau$  do
8:       if  $\text{cov}(A) > \text{cov}(A^*)$  then
9:          $A^* \leftarrow A$ 
10:      end if
11:    end for
12:  until  $\mathcal{A}_t = \emptyset$ 
13:  return  $A^*$ 
14: end function
```

▷ KL-LUCB — slide précédente

GenerateCands ajoute un predicate à chaque candidate ; B-BestCand garde les B meilleures par KL-LUCB (slide précédente).

II — Expériences des auteurs

Protocole, résultats publiés, et notre reproduction


Protocole expérimental (Ribeiro et al.)

Datasets

Adult • RCDV • Lending

Modèles

Logistic Regression (lr) • 400 Gradient Boosted
Trees (gbt) • MLP 2×50 (nn)



Anchor

lime-n
application naïve

lime-t
seuil calé sur la precision d'anchor (oracle)

Résultats publiés par Ribeiro et al. (2018) — Table 4

Dataset	Modèle	Precision (%)		Coverage (%)	
		anchor	lime-n	anchor	lime-t
adult	logistic	95.6	81.0	10.7	21.6
	gbt	96.2	81.0	9.7	20.2
	nn	95.6	79.6	7.6	17.3
rcdv	logistic	95.8	76.6	6.8	17.3
	gbt	94.8	71.7	4.8	2.6
	nn	93.4	65.7	1.1	1.5
lending	logistic	99.7	80.2	28.6	12.2
	gbt	99.3	79.9	28.4	9.1
	nn	96.7	77.0	16.6	5.4

lime-n : application naïve • *lime-t* : seuil calé sur la precision d'anchor (oracle, non réalisable par un utilisateur réel)

Anchors : meilleure garantie de précision et couverture explicitement définie ; la couverture varie fortement selon dataset et modèle.

Notre reproduction de l'expérience Adult



Mesure (Adult, gbt)	Article	Notre reproduction
Precision anchor (%)	96.2	XX.X
Coverage anchor (%)	9.7	XX.X
Precision lime-n (%)	81.0	XX.X
Coverage lime-t (%)	20.2	XX.X


Reproduction en cours

III — Limites et Alibi

Ce que les auteurs identifient eux-mêmes, et l'outil moderne qui en hérite

Limites identifiées par les auteurs

1. **Anchors trop spécifiques** Près d'une frontière de décision ou pour une classe rare : anchor longue, faible coverage, peu généralisable.
2. **Anchors conflictuelles** Deux anchors à prédictions différentes sur la même instance — rare (garantie de précision, submodular pick), mais possible.
3. **Espaces de sortie complexes** Sorties structurées (multi-label, séquences) : n'explique qu'une fonction de la sortie, pas l'espace complet.
4. **Distributions de perturbation réalistes** Trouver D à la fois expressive et interprétable reste ouvert — particulièrement pour les images.




IF Country = United-States **AND** Capital Loss = Low
AND Race = White **AND** Relationship = Husband
AND Married **AND** 28 < Age ≤ 37
AND Sex = Male **AND** High School grad
AND Occupation = Blue-Collar
THEN PREDICT Salary > \$50K

Illustration de la limite 1 : anchor longue (9 conditions) près d'une frontière de décision.

La limite 4 devient directement observable avec les images (Partie IV).

Alibi Explain : une implémentation moderne



Dans l'article (JMLR, 2021)

API unifiée `fit/explain`, couverture tabulaire/texte/image (Table 2), exemple `AnchorTabular` (Code Snippet 1).


Constaté par inspection du code

Les trois modalités partagent le même moteur de recherche (`AnchorBaseBeam`) — non détaillé dans l'article lui-même.

IV — Anchors pour les images

De l'adaptation par Alibi à une expérimentation personnelle contrôlée


AnchorImage : adaptation aux images



(a) Original image



(b) Anchor for "beagle"



(c) Images where Inception predicts $P(\text{beagle}) > 90\%$

Anchor pour « beagle » : quelques superpixels suffisent, sur plusieurs fonds, à maintenir la prédiction.

Exemple de l'article ; adaptation Alibi étudiée ensuite.

Mon expérimentation : protocole




+ Code

+ Markdown

`n_segments=10` $\rightarrow$ $K = 6$ (peu exploitable) $\Rightarrow$ `n_segments=50` $\rightarrow$ $K = 43$ (retenu)

Modèle : ResNet18 (IMAGENET1K_V1) • Image : `skimage.data.chelsea()` • Segmentation : SLIC
`threshold=0.95, tau=0.15, beam_size=1, p_sample=0.5, seed=42`

Prédiction et anchor obtenue



De gauche à droite : image originale — superpixels de l'anchor ($|A| = 4$) — masque binaire — image masquée

Classe (top-5)	probabilité
Egyptian cat	0.3905
tiger cat	0.3867
tabby	0.2179
lynx	0.0045
Persian cat	0.0002

$$A = \{15, 28, 14, 30\}$$


4 superpixels sur 43

Precision, coverage et stabilité

Mesure	Alibi	Vérif. indép.
Precision	0.9537	0.9633
Coverage	0.0624	0.0520

$IC_{95\%} = [0.9421; 0.9846]$


Coverage $\approx 0.5^4 = 0.0625$, cohérent avec $p_{\text{sample}}=0.5$.



À ne pas confondre

Association / stabilité observée dans $D \neq$ causalité — ce résultat décrit un lien statistique sous la distribution de perturbation utilisée, pas un mécanisme causal démontré.

Test hors de $D(z|A)$ — 4 essais illustratifs



L'anchor $A = [15, 28, 14, 30]$ suffit-elle à elle seule, hors de $D(z|A)$, à déclencher 'Egyptian cat' ?

Fond	Classe prédite	$P(\text{Egyptian cat})$	$= f(x) ?$
Noir	conch	0.0000	non
Bruit aléatoire	mask	0.0003	non
Damier	gong	0.0000	non
Photo sans rapport (tasse)	espresso	0.0000	non

Les 4 superpixels ne suffisent pas hors de $D(z|A)$: la stabilité observée dépend de la distribution de perturbations utilisée pendant la recherche.

Ce qui est observé

Dans $D(z|A)$, conserver les 4 superpixels suffit généralement à préserver la prédiction.

Ce qui est suggéré

Ces régions jouent un rôle important dans la décision du modèle, dans cette distribution locale de perturbations.

Ce qui n'est pas démontré

Causalité • robustesse hors distribution • suffisance intrinsèque des superpixels • robustesse aux paramètres • généralisation à d'autres images/modèles

V — Limites, enseignements, perspectives

Ce que cette exploration apporte, et ce qui reste à faire

Forces

- Règle simple, lisible
- Precision explicite (garantie probabiliste)
- Coverage explicite
- Compréhension humaine facilitée (étude utilisateurs)
- Model-agnostic
- Applicable à plusieurs modalités (tabulaire, texte, image)

Faiblesses

- Dépendance forte à D
- Coût computationnel (recherche, échantillonnage)
- Anchors parfois très spécifiques
- Espaces de sortie complexes
- Perturbations réalistes difficiles à définir
- Risque de surinterprétation (cf. Partie IV)

Synthèse croisée : article fondateur, bibliothèque Alibi, et expérimentation personnelle (Parties I à IV).

Quelques travaux récents liés à Anchors

Analyse théorique

A Sea of Words

Lopardo, Precioso, Garreau — AISTATS 2023

Premières garanties mathématiques sur Anchors, pour des classifieurs de texte (TF-IDF, modèles linéaires).

Limite : cadre restreint, ne couvre pas le cas boîte noire général.

Efficacité

MAnchors

Yu, Liu, Zhang — preprint 2025

Mémoire et réutilise des règles déjà trouvées pour accélérer la recherche (tabulaire, texte, image).

Limite : non encore publié ni relu par les pairs.

Application

From Rules to Reports


Festa et al. — Ital-IA 2025

Combine Anchors et un LLM pour produire des rapports cliniques en langage naturel (prédiction du diabète).

Limite : évaluation qualitative seule, pas de validation clinique.


Trois directions actuelles : mieux comprendre Anchors, le rendre plus rapide, le rendre exploitable en pratique.

Ce que j'ai appris de cette exploration



- Explication locale vs globale
- Precision, coverage
- Distributions de perturbation
- Recherche par règles (greedy, beam search, bandit)
- Importance de l'espace interprétable
- Limites des explications locales

Lien avec mon projet de recherche



Anchors produit une règle locale — la suite explore des représentations plus structurées

règles → concepts (**FCA**) → relations → ontologies → knowledge graphs → raisonnement symbolique

Anchors n'est pas une méthode FCA : c'est une étape de compréhension et un point de comparaison pour la suite.

Objectifs de la suite

- ➊ Approfondir Formal Concept Analysis
- ➋ Étudier les travaux récents
- ➌ Comprendre comment les concepts sont extraits des données
- ➍ Étudier la représentation du comportement des classes
- ➎ Comparer règles, FCA, ontologies, knowledge graphs, raisonnement symbolique
- ➏ Identifier les points de rencontre avec XAI

Une règle locale suffit-elle, ou faut-il une structure plus riche pour représenter le comportement d'un modèle ?

Références I



Francesco Festa, Antonio Della Porta, Viviana Pentangelo, and Fabio Palomba.
From rules to reports : Enhancing diabetes prediction interpretability with anchor and llms.
In Ital-IA 2025 : 5th National Conference on Artificial Intelligence, Trieste, Italy, 2025.



Janis Klaise, Arnaud Van Looveren, Giovanni Vacanti, and Alexandru Coca.
Alibi explain : Algorithms for explaining machine learning models.
Journal of Machine Learning Research, 22 :1–7, 2021.



Gianluigi Lopardo, Frederic Precioso, and Damien Garreau.
A sea of words : An in-depth analysis of anchors for text data.
In Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS),
volume 206 of *Proceedings of Machine Learning Research*, pages 4848–4879, 2023.



Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin.
Anchors : High-precision model-agnostic explanations.
In Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence (AAAI-18), pages 1527–1535.
AAAI Press, 2018.

Références II



Haonan Yu, Junhao Liu, and Xin Zhang.

Manchors : Memorization-based acceleration of anchors via rule reuse and transformation, 2025.