

Exploration de l'interprétabilité des modèles de Machine Learning

De l'Explainable AI aux représentations structurées :
premières explorations autour de Formal Concept Analysis

Fokouo Luciano

Master 2 Data Science

14 août 2026


Plan de la présentation

- 1 Introduction
- 2 Contexte et cartographie de l'interprétabilité
- 3 Méthodes d'interprétation
- 4 Construire des modèles interprétables
- 5 Formal Concept Analysis
- 6 FCA et information incomplète
- 7 Synthèse et suite de l'exploration

Objectifs de l'exploration

- Comprendre les principales notions d'interprétabilité
- Cartographier les grandes familles de méthodes existantes
- Comprendre leurs mécanismes de fonctionnement et leurs limites
- Identifier les approches produisant des représentations réellement compréhensibles
- Explorer les modèles intrinsèquement interprétables
- Commencer une exploration approfondie de Formal Concept Analysis (FCA)

Point de départ : le problème de la boîte noire



Comment comprendre cette prédiction ?

Black-box models

Deep learning, ensemble learning

White-box / intrinsèquement interprétables

Modèles linéaires, arbres de décision, modèles à règles

I — Contexte et cartographie de l'interprétabilité

Qu'est-ce que l'interprétabilité et comment la littérature la structure-t-elle ?

Interprétabilité et explicabilité

Doshi-Velez & Kim

« the ability to explain or to present in understandable terms to a human »

Miller

« the degree to which a human can understand the cause of a decision »

- **Interprétabilité** : compréhension intuitive du lien cause-effet entre entrées et sorties, sans nécessiter d'ouvrir le modèle
- **Explicabilité** : compréhension de la logique et des mécanismes *internes* du modèle (entraînement, calculs, décisions)
- Les deux notions sont **indépendantes** : l'une n'implique pas l'autre
- L'interprétabilité est considérée ici comme le terme le plus **englobant**

Une distinction qui ne fait pas consensus

À noter

Il n'existe pas de définition mathématique rigoureuse ni de métrique consensuelle pour ces deux termes [?].

- **Molnar** : distingue plutôt selon la *méthode* —
 - interprétabilité = transparence *par construction* (ex. régression linéaire)
 - explicabilité = méthode *post-hoc* appliquée à une boîte noire (SHAP, LIME)
- **Rudin (2019)** : critique l'explicabilité post-hoc pour les décisions à fort enjeu — préfère des modèles nativement interprétables, jugés plus fiables
- **Gilpin et al.** : l'interprétabilité seule est insuffisante ; l'explicabilité reste nécessaire en complément

À retenir : le sens exact dépend de l'auteur — préciser systématiquement la définition utilisée

Quelques travaux structurants

Travail	Objectif	Apport pour notre exploration
Gilpin et al.	Interprétabilité du deep learning ; taxonomie des méthodes d'interprétabilité pour réseaux de neurones	Cadre de référence pour situer les méthodes propres au deep learning
Adadi & Berrada	Revue de littérature XAI (plus de 380 travaux analysés)	Vision d'ensemble du champ de l'XAI
Guidotti et al.	Catégorisation des méthodes XAI	Distinction entre expliquer les black-box models, inspecter les black-box models, expliquer les décisions, et construire des modèles interprétables

discutés dans la revue de Linardatos, Papastefanopoulos & Kotsiantis (2021), notre principal fil conducteur pour les Parties II et III.

Gilpin et al. : trois catégories pour le deep learning

1. Émuler le traitement des données

Créer des indices sur les connexions entre entrées et sorties du modèle

2. Expliquer la représentation interne

Expliquer comment les données sont représentées à l'intérieur du réseau

3. Réseaux transparents

Réseaux conçus pour s'expliquer eux-mêmes

Gilpin et al. soulignent aussi le manque d'approches combinatoires, qui mêleraient plusieurs techniques d'explication.

Deux dimensions utiles pour cartographier les méthodes

Model-specific

Méthode liée à une famille particulière de modèles

Model-agnostic

Méthode applicable indépendamment du modèle sous-jacent

Local

Explique une instance, une décision particulière

Global

Cherche à caractériser le comportement général du modèle

	Model-specific	Model-agnostic
Local	Grad-CAM, Integrated Gradients	LIME, SHAP, Anchors
Global	—	PDP

Ces dimensions peuvent se combiner : elles ne forment pas quatre catégories exclusives.

Qu'est-ce qu'une méthode XAI produit réellement ?

- Importance / attribution de variables
- Carte de saillance
- Modèle local
- Règle
- Contre-factuel
- Prototype / exemple
- Courbe de dépendance

À retenir

Les méthodes XAI ne produisent pas toutes le même type de connaissance : certaines livrent un score, d'autres une structure symbolique.

II — Méthodes d'interprétation

De l'attribution locale aux représentations symboliques

$$\frac{\partial f(x)}{\partial x_i}$$


Intuition

« Si je modifie légèrement x_i autour de x , à quel point la sortie du modèle varie-t-elle ? »

- Calcul par rétropropagation
- Méthode rapide
- Locale
- Permet d'obtenir des cartes de saillance pour les images

Le gradient mesure une sensibilité locale de la sortie par rapport aux entrées — il n'« explique » pas la décision en soi.

Exemple : cartes de saillance



Cartes de saillance obtenues par la méthode des gradients simples, sur plusieurs images de test.

Integrated Gradients : de la sensibilité à l'attribution

Gradient simple


→ sensibilité locale

Integrated Gradients

→ accumuler les sensibilités le long d'un chemin entre une baseline et l'entrée

$$IG_i(x) = (x_i - x'_i) \int_0^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_i} d\alpha$$

- x' = baseline
- x = observation
- α = position sur le chemin




Attribution par intégration des sensibilités.


Exemple : chemin d'interpolation

Étape 1 — Chemin d'interpolation : de la baseline vide à l'image réelle


baseline
(vide)




$\alpha=0.20$



$\alpha=0.40$



$\alpha=0.60$



$\alpha=0.80$





image
réelle



Le chemin part d'une baseline noire (aucune information) et rejoint progressivement l'image réelle, à mesure que α croît de 0 à 1. *Modèle : MobileNetV2 pré-entraîné sur ImageNet. Photo : Richard Brutyo (Unsplash).*

Exemple : évolution de la confiance le long du chemin




À chaque α , on mesure la probabilité prédite pour la classe cible. La variation de cette courbe le long du chemin correspond précisément au terme de gradient intégré dans la formule d'IG.

Exemple : attribution finale

Image source



Étape 3 — Attribution (IG) : « golden_retriever »




Carte d'attribution obtenue en intégrant les gradients le long du chemin. Modèle : MobileNetV2 (ImageNet) — classe prédite : *golden retriever*. Photo : Richard Brutyo (Unsplash).

Autres méthodes en deep learning

Méthode	Idée	Objet produit
Integrated Gradients	Accumuler les sensibilités le long d'un chemin baseline → entrée	Attribution de caractéristiques
Guided Backpropagation	Visualiser les activations / gradients jugés utiles	Visualisation des activations
Grad-CAM	Pondérer les feature maps selon la classe cible	Régions importantes pour une classe, dans une image

LIME : expliquer une prédiction localement



LIME cherche un modèle interprétable local g qui approxime le comportement du modèle complexe f autour de l'instance étudiée.

$$\xi(x) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g)$$

Limite : instabilité de LIME

- Perturbation aléatoire de l'instance
- Sélection de caractéristiques instable
- Possibilité d'obtenir différentes explications pour la même instance

Discuté notamment par Zafar & Khan.

LIME

Perturbations aléatoires

DLIME

Clustering hiérarchique → KNN → sélection du cluster → explication plus déterministe

Résultat rapporté dans l'étude : comparaison sur trois jeux de données médicaux, avec une amélioration en termes de Jaccard Similarity (valeurs numériques non reproduites ici).

SHAP : répartir la responsabilité d'une prédiction

« Existe-t-il une manière théoriquement juste de répartir la responsabilité d'une prédiction entre les variables ? »

Intuition issue des valeurs de Shapley (théorie des jeux) :

- Contribution individuelle de chaque variable
- Prise en compte des combinaisons de variables
- Attribution de la sortie du modèle

Propriétés étudiées

Local accuracy • Missingness • Consistency

SHAP propose une classe unifiée de méthodes d'attribution additive, regroupant six méthodes existantes dont LIME, DeepLIFT et Layer-Wise Relevance Propagation.

SHAP : intérêt et limites conceptuelles

- Model-agnostic dans certaines formulations
- Méthode d'attribution
- Très utilisée dans la littérature XAI

Attention

Les SHAP values ne constituent pas une explication causale.

importance / contribution $\neq$ règle symbolique

Anchors : passer de l'importance à une règle

« Quelles conditions locales sont suffisantes pour maintenir la prédiction ? »

SI glucose élevé

ET BMI élevé

ALORS classe = diabète

- Commencer avec une règle vide
- Générer des candidats
- Sélectionner progressivement les conditions
- Choisir les candidats à forte précision
- Arrêter lorsqu'une condition satisfait la définition d'un anchor

Définition intuitive

Une anchor est une règle qui, localement, maintient la prédiction avec une forte précision malgré des variations sur les autres caractéristiques.

Le résultat n'est plus un score d'importance : c'est une condition symbolique.

« Pourquoi cette prédiction plutôt qu'une autre ? »


CEM cherche :

- Les caractéristiques minimales et suffisantes **présentes**
- Les caractéristiques minimales mais critiques **absentes**

Un rapprochement est fait avec la structure des explications humaines.

Counterfactual explanations

« Quel changement minimal aurait permis d'obtenir une autre prédiction ? »



Limite discutée

Un contre-factuel ne cherche pas nécessairement à révéler le fonctionnement interne du modèle ; pris isolément, il peut être insuffisant pour comprendre le fonctionnement global d'une black-box.

PDP / ICE / ALE : analyser la dépendance entre variables et prédictions

- **PDP** (Partial Dependence Plot) : effet moyen d'une variable sur la prédiction
- **ICE** (Individual Conditional Expectation) : effet d'une variable, instance par instance
- **ALE** (Accumulated Local Effects) : effet local accumulé, moins sensible aux corrélations entre variables

Rôle dans la cartographie

Ces méthodes analysent la relation entre variables et prédictions, plutôt que de produire directement une règle symbolique.

III — Construire des modèles interprétables

Plutôt qu'expliquer une boîte noire après coup, peut-on construire directement un modèle dont le fonctionnement est compréhensible ?

Generalized Additive Models with pairwise interactions

$$g(\mathbb{E}[y]) = \beta_0 + \sum_i f_i(x_i) + \sum_{i < j} f_{ij}(x_i, x_j)$$

- Contribution individuelle visible (f_i)
- Interactions explicites entre paires de variables (f_{ij})
- Structure modulaire
- Modèle interprétable par construction

Caruana et al. (2015) ont obtenu une performance état de l'art sur deux applications médicales réelles — prédiction du risque de pneumonie et de réadmission hospitalière à 30 jours — sans que cela ne signifie que GA2M égale systématiquement le deep learning.

Modèles à règles : interprétabilité par structure symbolique

Boolean Rule Column Generation

$$(x_1 \wedge x_3) \vee (x_2 \wedge \neg x_4)$$

- Formes normales : DNF, CNF
- Recherche de règles satisfaisant un compromis précision / simplicité
- Espace des règles potentiellement exponentiel
- Utilisation d'une stratégie de column generation pour une recherche efficace, telle que décrite dans le travail étudié

TED : produire des explications proches du raisonnement humain

- Framework pour produire des explications locales
- Objectif : refléter un raisonnement humain / de domaine
- Ne cherche pas nécessairement à reproduire le raisonnement interne exact de la black-box
- Recours à un expert et à des connaissances de domaine, selon le cadre présenté dans la revue

Ce que ces méthodes nous montrent

Post-hoc

Expliquent un modèle existant

Intrinsèquement interprétables

Construisent directement une structure compréhensible

Règles / Anchors

Produisent une représentation symbolique locale

« Peut-on représenter plus systématiquement les relations entre objets, attributs et concepts ? »

Nous avons donc commencé à explorer FCA comme une formalisation possible de ces relations.

IV — Formal Concept Analysis

Explorer une représentation formelle des relations objets-attributs

Pourquoi introduire Formal Concept Analysis ?

- On dispose d'un ensemble d'**objets**
- On dispose d'un ensemble d'**attributs**
- On sait quels objets possèdent quels attributs
- FCA permet de structurer cette information en **concepts**, puis en relations entre concepts

Où en sommes-nous ?

Nous sommes encore dans une phase d'exploration : FCA est une piste étudiée parmi d'autres pour représenter et structurer des relations entre objets et attributs.

Formal Context — intuition

Un exemple simple : trois personnes, trois attributs.

Objet	Client	Salarié	Propriétaire
Alice	✓	✓	✓
Bob	✓	✓	×
Emma	✓	×	✓

- X = ensemble des objets (Alice, Bob, Emma)
- A = ensemble des attributs (Client, Salarié, Propriétaire)
- une relation indique quel objet possède quel attribut

$$FC = (X, A, R), \quad R \subseteq X \times A$$

$(x, a) \in R \iff$ l'objet x possède l'attribut a

Interprétation

Le tableau est la représentation concrète. La définition mathématique formalise exactement ce que contient le tableau.

Exemple construit pour l'illustration.

Derivation operators

Intuition

À partir d'un ensemble d'objets, on cherche les attributs communs à **tous** ces objets.

À partir d'un ensemble d'attributs, on cherche les objets qui possèdent **tous** ces attributs.

$$Y^{\uparrow} = \{ a \in A \mid (x, a) \in R, \forall x \in Y \}$$

$$B^{\downarrow} = \{ x \in X \mid (x, a) \in R, \forall a \in B \}$$

$Y^{\uparrow}$: « Quels attributs sont communs à tous les objets de Y ? »


$B^{\downarrow}$: « Quels objets possèdent tous les attributs de B ? »

Derivation operators — exemple

Calcul

$$Y = \{\text{Alice}, \text{Bob}\} \Rightarrow Y^\uparrow = \{\text{Client}, \text{Salarié}\}$$

$$B = \{\text{Client}, \text{Salarié}\} \Rightarrow B^\downarrow = \{\text{Alice}, \text{Bob}\}$$



Les deux ensembles se « renvoient » exactement l'un à l'autre : c'est ce caractère de fermeture qui permet de construire les concepts.

Formal Concept

Un concept FCA n'est pas simplement un objet ou un attribut : c'est un couple (extent, intent).

Définition

(Y, B) est un concept si $Y^\uparrow = B$ et $B^\downarrow = Y$

c'est-à-dire $(Y, B) = (B^\downarrow, Y^\uparrow)$

On part des objets, on récupère leurs attributs communs, puis on revient aux objets qui possèdent ces attributs. Si on retrouve exactement le même ensemble d'objets, on a un concept fermé.

Formal Concept — exemples

Concept 1

Extent = {Alice, Bob}

Intent = {Client, Salarié}


Concept 2

Extent = {Alice}

Intent = {Client, Salarié, Propriétaire}

Un concept est une unité de connaissance : ces objets partagent exactement ces propriétés.

Extension vs Intension



- **Extension** : les objets concernés par le concept
- **Intent** : les attributs communs qui caractérisent ces objets

Extension et intent sont liées par les opérateurs de dérivation $\uparrow$ et $\downarrow$.

Concept Lattice — organiser les concepts

« Nous avons maintenant plusieurs concepts. Comment les organiser entre eux ? »

Un concept peut être plus général ou plus spécifique qu'un autre : c'est l'**ordre conceptuel**.


En descendant

L'ensemble des objets diminue ; l'ensemble des attributs augmente

En remontant

Davantage d'objets ; moins d'attributs

Concept Lattice — diagramme



Chaque nœud affiche (extent | intent). Exemple construit à partir du contexte Alice/Bob/Emma.

Comment lire un concept lattice ?

- Un nœud = un concept
- Les liens représentent une relation d'ordre
- Les concepts supérieurs sont plus généraux
- Les concepts inférieurs sont plus spécifiques
- Descendre ajoute des attributs et réduit généralement l'extension
- Remonter retire des contraintes et élargit l'extension

Dans notre exemple : le concept du haut (Client) est le plus général ; celui du bas (Alice, avec ses trois attributs) est le plus spécifique.

Propriétaire $\Rightarrow$ Client

Vérifié dans notre exemple : Alice et Emma possèdent Propriétaire, et toutes deux possèdent aussi Client.

Intuition

Une implication décrit une régularité dans les données : chaque fois qu'un ensemble d'attributs est présent, un autre attribut l'est aussi, pour tous les objets du contexte.

FCA ne produit donc pas seulement des groupes d'objets : elle permet aussi d'extraire des relations structurées entre attributs. Nous ne développons pas ici la théorie complète des implications, qui n'a pas été approfondie dans notre exploration.

Clustering conceptuel

Les concepts regroupent naturellement les objets partageant des propriétés.

Clustering classique	Clustering conceptuel
Distance / similarité entre points	Attributs partagés entre objets
Groupes numériques	Concepts organisés dans un treillis

Il ne s'agit pas d'une supériorité générale de FCA : c'est un mode de regroupement différent, fondé sur les attributs partagés et la structure du treillis.

V — FCA et information incomplète

Comment FCA traite-t-elle l'information incomplète et l'incertitude ?

Limite du contexte classique : que signifie une cellule vide ?

Dans un contexte classique, l'absence de relation entre un objet et un attribut peut être interprétée de plusieurs manières :

- ① L'objet ne possède pas l'attribut
- ② On ne sait pas si l'objet possède l'attribut
- ③ L'attribut est éventuellement sans signification pour cet objet

Article étudié

Fernando Chacón-Gómez, M. Eugenia Cornejo, Didier Dubois, Jesús Medina, Henri Prade
Handling incomplete information in formal concept analysis : a possibilistic approach, 2026

Ontic vs Epistemic

Ontic

Absence de relation = l'objet ne possède pas l'attribut

Epistemic

Absence de relation = on ne sait pas si l'objet possède l'attribut

L'article étudié considère les deux perspectives simultanément, avec une représentation permettant de distinguer explicitement les différents cas.

Représentation à trois valeurs

$$R : X \times A \rightarrow \{+, -, ?\}$$

+	−	?
relation connue comme vraie	relation connue comme fausse	relation inconnue

	A_1	A_2	A_3
x_1	+	−	?
x_2	+	?	+
x_3	?	−	+

Complete / Standard / Incomplete Context

$$CC = (X, A, \{+, -\}, R_{CC}) \quad SC = (X, A, \{+, ?\}, R_{SC}) \quad IC = (X, A, \{+, -, ?\}, R_{IC})$$

Contexte	Valeurs	Signification
Complete (CC)	+, -	Connaissance complète
Standard (SC)	+, ?	Information positive ou inconnue
Incomplete (IC)	+, -, ?	Positive, négative et inconnue

Derivation operators dans le cas incomplet

Intuition

$\Box$ = ce qui est **certainement** vrai $\Diamond$ = ce qui est **possiblement** vrai

$$Y^{\uparrow\Box} = \{a \in A \mid R_{IC}(x, a) = +, \forall x \in Y\} \quad B^{\downarrow\Box} = \{x \in X \mid R_{IC}(x, a) = +, \forall a \in B\}$$

$$Y^{\uparrow\Diamond} = \{a \in A \mid R_{IC}(x, a) \neq -, \forall x \in Y\} \quad B^{\downarrow\Diamond} = \{x \in X \mid R_{IC}(x, a) \neq -, \forall a \in B\}$$

Cette distinction certain / possible est centrale pour raisonner sur un contexte incomplet.

Exemple des deux dérivations

	A_1	A_2	A_3
x_1	+	-	?
x_2	+	?	+

Pour $Y = \{x_1, x_2\}$

$Y^{\uparrow\Box} = \{A_1\}$ (certain)

$Y^{\uparrow\Diamond} = \{A_1, A_3\}$ (possible)

A_2 est exclue des deux : x_1 ne la possède certainement pas. A_3 n'est pas certainement commune (inconnue pour x_1), mais reste possible pour les deux objets : c'est exactement ce que l'information inconnue permet de représenter. Exemple construit pour l'illustration.

Définition

Une completion remplace chaque ? par + ou - : pour supprimer l'incertitude, on choisit un scénario complet.

$$IC \longrightarrow CO_1, CO_2, \dots = \text{Comp}(IC)$$

$$|\text{Comp}(IC)| = 2^n$$

Exemple : notre contexte IC (3 cellules inconnues, $n = 3$) admet $2^3 = 8$ complétions possibles — chaque ? peut être résolu indépendamment en + ou en -.

Lower / Upper Completion

Lower completion (CO_l)

Tous les ? deviennent –

	A_1	A_2	A_3
x_1	+	–	–
x_2	+	–	+
x_3	–	–	+

Upper completion (CO_u)

Tous les ? deviennent +

	A_1	A_2	A_3
x_1	+	–	+
x_2	+	+	+
x_3	+	–	+

Toutes les autres complétions se situent entre ces deux cas extrêmes, selon l'ordre défini dans l'article.

Lien entre dérivation et completions

Intuition

Le certain est contenu dans ce qui est vrai dans une complétion quelconque, qui est lui-même contenu dans le possible.

$$B^{\downarrow \Box} = B^{\downarrow c}_{CO_l} \qquad B^{\downarrow \Diamond} = B^{\downarrow c}_{CO_u}$$

$$B^{\downarrow \Box} \subseteq B^{\downarrow c}_{CO} \subseteq B^{\downarrow \Diamond}$$

La dérivation « certainement vraie » correspond à la lower completion ; la dérivation « possiblement vraie » correspond à la upper completion.

« Nous avons plusieurs complétions possibles. Comment représenter mathématiquement cette incertitude ? »

$$\pi : U \rightarrow [0, 1]$$

- $\pi(u) = 0$: scénario impossible
- $\pi(u) = 1$: scénario totalement plausible

Dans le cas étudié, les complétions compatibles ont une possibilité de 1, et les autres une possibilité de 0 (cas binaire).

Possibility vs Necessity

$$\Pi(E) = \max_{s \in E} \pi(s)$$

$$N(E) = 1 - \max_{s \notin E} \pi(s)$$

Possibilité

Existe-t-il au moins un scénario compatible dans lequel E est vrai ?

Nécessité

Tous les scénarios compatibles rendent-ils E vrai ?

Application aux contextes incomplets

Une complete context CC est possible par rapport à IC si elle est compatible avec IC :

$$\pi_{IC}(CC) = 1 \iff CC \in \text{Comp}(IC), \quad \text{sinon } \pi_{IC}(CC) = 0$$

Les complétions représentent exactement les scénarios compatibles avec les connaissances disponibles.

Résultats : possibilité et nécessité pour un ensemble de contextes

Pour un ensemble C de contextes complets :

$$\Pi_{IC}(C) = 1 \text{ si } C \cap \text{Comp}(IC) \neq \emptyset$$

$$N_{IC}(C) = 1 \text{ si } \text{Comp}(IC) \subseteq C$$

- Possibilité = au moins un scénario compatible est présent dans C
- Nécessité = tous les scénarios compatibles sont présents dans C

Exemple illustratif : possibilité et nécessité

Notre contexte IC (3 cellules inconnues) admet 8 complétions compatibles. Soit l'événement :

$$C = \text{« } x_3 \text{ possède } A_1 \text{ »}$$

- 4 des 8 complétions compatibles vérifient $C \Rightarrow \Pi_{IC}(C) = 1$ (possible)
- 4 autres complétions compatibles ne vérifient pas $C \Rightarrow N_{IC}(C) = 0$ (non nécessaire)

C est possible mais pas nécessaire : tous les scénarios compatibles ne sont pas représentés dans C. Exemple construit pour l'illustration, à partir du contexte x_1, x_2, x_3 .

Synthèse : ce que nous avons appris sur FCA

Formal Context

Objects, Attributes, Relation

Dérivation

↑ et ↓

Formal Concepts

Extent, Intent

Concept Lattice

Ordre, hiérarchie, clustering conceptuel

FCA incomplète

+ / - / ?, $\square$ / $\diamond$, completions, lower / upper, possibilité / nécessité

Lien avec le projet de recherche

Notre encadreur nous a orientés vers plusieurs pistes : FCA, ontologies, systèmes experts, explicabilité, modèles interprétables / white-box.

Pourquoi FCA nous intéresse actuellement

données → attributs partagés → concepts → hiérarchie de concepts → relations / implications


Il reste à déterminer si cette représentation est réellement adaptée à l'explication des prédictions de modèles de Machine Learning.

C'est une question de recherche, pas une conclusion.

VI — Synthèse et suite de l'exploration

Qu'avons-nous appris et quelles questions restent ouvertes ?

Où se situe FCA dans notre exploration ?



Ce que nous avons appris

Niveau 1

Comprendre les méthodes XAI

Niveau 2

Comprendre les modèles intrinsèquement interprétables et les représentations symboliques

Niveau 3

Commencer à comprendre FCA mathématiquement : formal context, derivation operators, formal concepts, intention / extension, concept lattice, clustering conceptuel, information incomplète, completions, possibilité / nécessité

Ce qui reste ouvert

- ❶ Comment comparer FCA aux ontologies comme représentation de connaissances ?
- ❷ Comment les représentations FCA peuvent-elles être exploitées pour expliquer des modèles ML ?
- ❸ Peut-on apprendre des modèles intrinsèquement interprétables à partir de structures FCA ?
- ❹ Quel rôle peuvent jouer les règles / implications extraites de FCA ?
- ❺ Comment gérer l'information incertaine ou incomplète dans une représentation utilisée pour l'explication ?
- ❻ Quel lien avec les systèmes experts et éventuellement les GNN ?

Ce sont des pistes d'exploration, pas des questions présentées comme originales au sens scientifique.

État actuel de l'exploration

Nous sommes partis de l'interprétabilité des modèles ML et avons étudié plusieurs familles de méthodes, depuis les attributions numériques jusqu'aux règles et aux modèles interprétables par construction.

Cette exploration a conduit à étudier FCA comme une approche formelle permettant de structurer les relations entre objets et attributs et d'organiser des concepts.

L'étude de l'information incomplète a également montré comment FCA peut être étendue pour raisonner sur plusieurs scénarios possibles et introduire des notions de possibilité et de nécessité.

Prochaine étape

Comparer cette piste avec les ontologies, les systèmes experts et les autres représentations symboliques, avant de déterminer une problématique de recherche.

Références I

-  Linardatos, P., Papastefanopoulos, V., Kotsiantis, S. *Explainable AI : A Review of Machine Learning Interpretability Methods*. Entropy, 2021. (source principale, Parties II–III)
-  Doshi-Velez, F., Kim, B. *Towards a rigorous science of interpretable machine learning*. arXiv, 2017.
-  Miller, T. *Explanation in artificial intelligence : Insights from the social sciences*. Artificial Intelligence, 2019.
-  Gilpin, L.H. et al. *Explaining explanations : An overview of interpretability of machine learning*. 2018.
-  Adadi, A., Berrada, M. *Peeking inside the black-box : A survey on Explainable Artificial Intelligence (XAI)*. IEEE Access, 2018.
-  Guidotti, R. et al. *A survey of methods for explaining black box models*. ACM Computing Surveys, 2018.
-  Ribeiro, M.T., Singh, S., Guestrin, C. « *Why should I trust you ?* » *Explaining the predictions of any classifier*. 2016.
-  Zafar, M.R., Khan, N.M. *DLIME : A deterministic local interpretable model-agnostic explanations approach for computer-aided diagnosis systems*. arXiv, 2019.

Références II

-  Lundberg, S.M., Lee, S.I. *A unified approach to interpreting model predictions*. 2017.
-  Ribeiro, M.T., Singh, S., Guestrin, C. *Anchors : High-precision model-agnostic explanations*. 2018.
-  Dhurandhar, A. et al. *Explanations based on the missing : Towards contrastive explanations with pertinent negatives*. 2018.
-  Wachter, S., Mittelstadt, B., Russell, C. *Counterfactual explanations without opening the black box : Automated decisions and the GDPR*. Harvard JL & Tech., 2017.
-  Van Looveren, A., Klaise, J. *Interpretable counterfactual explanations guided by prototypes*. arXiv, 2019.
-  Caruana, R. et al. *Intelligible models for healthcare : Predicting pneumonia risk and hospital 30-day readmission*. 2015.
-  Dash, S., Gunluk, O., Wei, D. *Boolean decision rules via column generation*. 2018.
-  Hind, M. et al. *TED : Teaching AI to explain its decisions*. 2019.

Références III



Chacón-Gómez, F., Cornejo, M.E., Dubois, D., Medina, J., Prade, H. *Handling incomplete information in formal concept analysis — a possibilistic approach*. Computational and Applied Mathematics, 2026.