

Classification supervisée fondée sur la Formal Concept Analysis

Lecture mécanisme par mécanisme de la survey d'Azibi, Meddouri & Maddouri — fil conducteur : comment chaque méthode gère l'ambiguïté multi-concepts / multi-classes

Fokouo Luciano

École Nationale Supérieure Polytechnique de Yaoundé
Master 2 Data Science

4 septembre 2026

Plan de la présentation

- 1 Rappels FCA et mini-dataset
- 2 Complete lattice methods
- 3 Sub-lattice methods
- 4 Concept cover methods
- 5 Perspectives

Objectifs de l'exploration

- Reconstituer, **mécanisme par mécanisme**, les méthodes de classification supervisée fondées sur la FCA recensées par la survey.
- Rejouer chaque mécanisme **sur un mini-dataset commun**, à la main, étape par étape.
- Suivre un **fil conducteur unique** : comment chaque méthode répond à l'ambiguïté *multi-concepts* / *multi-classes* — la question posée par Sangroya et al.

Le fil rouge :

une instance peut correspondre à des concepts de *classes différentes* — que fait alors chaque méthode ?

Définitions


- Contexte formel $K = (G, M, I)$: objets G , attributs M , relation $I \subseteq G \times M$.
- $A' = \{m \in M \mid \forall g \in A, (g, m) \in I\}$
- $B' = \{g \in G \mid \forall m \in B, (g, m) \in I\}$
- Concept formel (A, B) : $A' = B$ et $B' = A$ (A extension, B intention).
- Ordre :
 $(A_1, B_1) \leq (A_2, B_2) \iff A_1 \subseteq A_2 \iff B_2 \subseteq B_1$.
- $(\mathcal{B}(K), \leq)$ est un **treillis complet**.

Mini-dataset commun

	a	b	c	d	Classe
g_1	1	1	0	0	A
g_2	1	1	1	0	A
g_3	0	1	1	1	B
g_4	0	0	1	1	B
g_5	1	0	1	0	B

La **classe n'est pas un attribut** du contexte : le treillis est construit sur $\{a, b, c, d\}$; les classes ne servent qu'à l'étape de classification. Instances-test utilisées partout : $X_1 = \{a, c\}$, $X_2 = \{b, c\}$.




Treillis complet du mini-dataset — diagramme de Hasse (7 concepts)



Couvertures : $\top \rightarrow C_1, C_4, C_5$; $C_1 \rightarrow C_2$, $C_5 \rightarrow C_2$; $C_4 \rightarrow C_3$; $C_2, C_3 \rightarrow \perp$. Le concept mixte C_5 est la source de toute l'ambiguïté étudiée.

Trois familles selon la portion du treillis exploitée

La survey classe les méthodes selon *quelle part* du treillis de concepts intervient dans la décision.



Complete lattice

Le treillis **complet** est construit ; *tous* les concepts servent à la décision (concept le plus spécifique, similarité, règles).

GRAND, GALOIS, RULEARNER, NAVIGALA

Sub-lattice

On ne garde qu'un **sous-treillis filtré** en amont par un critère de qualité (validité, quasi-cohérence, pertinence, hauteur).

LEGAL, CIBLe/IGLUE, CLNN

Concept cover

Pas de treillis : par classe, un petit jeu de concepts choisi par compression (MDL) ; décision = comparaison des longueurs d'encodage.


MDL / Krimp

Famille 1 — Complete lattice methods

Le treillis complet est construit puis parcouru : GRAND, GALOIS, RULEARNER, NAVIGALA

GRAND — vote sur l'extension du concept le plus spécifique

Principe. On descend au concept le plus spécifique dont l'intention est incluse dans l'instance, puis on vote à la majorité sur les classes de son extension.



Gestion de l'ambiguïté : **MASQUER — égalité et absence de spécificité passées sous silence**

GALOIS — similarité instance / intention, k concepts les plus proches

Principe. On mesure la similarité entre l'instance X et l'intention B de chaque concept, on retient les plus proches, on vote sur leurs extensions.

$$\text{compte brut} = |X \cap B| \qquad \text{Jaccard} = \frac{|X \cap B|}{|X \cup B|}$$

Le dénominateur de Jaccard est la taille de l'union. Ex. avec $X_1 = \{a, c\}$: $J(X_1, C_2) = \frac{|\{a, c\}|}{|\{a, b, c\}|} = \frac{2}{3}$; $J(X_1, C_3) = \frac{|\{c\}|}{|\{a, b, c, d\}|} = \frac{1}{4}$;

$$J(X_1, C_5) = \frac{|\{a, c\}|}{|\{a, c\}|} = 1.$$

	$C_1\{a, b\}$	$C_5\{a, c\}$	$C_4\{c, d\}$	$C_2\{a, b, c\}$	$C_3\{b, c, d\}$
$X_1 = \{a, c\}$ — compte brut	1	2	1	2	1
X_1 — Jaccard	1/3	1.0	1/3	2/3	1/4
$X_2 = \{b, c\}$ — compte brut	1	1	1	2	2
X_2 — Jaccard	1/3	1/3	1/3	2/3	2/3



Le passage brut → Jaccard *déplace* l'ambiguïté (X_1) sans la supprimer, et ne change rien pour X_2 . Le score expose la mixité de C_5 au lieu de la dissimuler.


Gestion de l'ambiguïté : **RÉVÉLER — le score rend visible l'égalité et la mixité**

RULEARNER — règles concept $\rightarrow$ classe, ordonnées

Principe. Chaque concept « assez pur » produit une règle intention $\Rightarrow$ classe ; les règles sont triées (support, confiance) ; on applique la première règle satisfaite par l'instance.

Règle	Origine	Support	Confiance
$R_1 : \{a, b\} \Rightarrow A$	C_1	2	1.0
$R_2 : \{a, b, c\} \Rightarrow A$	C_2	1	1.0
$R_3 : \{c, d\} \Rightarrow B$	C_4	2	1.0
$R_4 : \{b, c, d\} \Rightarrow B$	C_3	1	1.0
$(\{a, c\} \Rightarrow ?)$	C_5 mixte	2	0.5 — écartée

Support d'une règle = taille de l'extension du concept d'origine (nb d'objets d'entraînement couverts) ; **confiance** = part de ces objets qui sont de la classe de la règle. Ex. $C_1 : \text{extension } \{g_1, g_2\} \Rightarrow \text{support } 2, 2/2 \text{ en } A \Rightarrow \text{confiance } 1.0$. $C_5 : \{g_2, g_5\} \Rightarrow \text{support } 2, 1/2 \text{ en } A \Rightarrow \text{confiance } 0.5$.



Arbitraire du choix d'ordre


Sur l'égalité C_2/C_3 (mêmes support et confiance), la sortie dépend d'un **ordre externe** : tri lexical, ordre d'énumération des concepts, ordre d'insertion. La théorie ne le fixe pas $\Rightarrow$ résultat *déterministe mais non justifié*.

Gestion de l'ambiguïté : **TRANCHER par un ordre externe non spécifié**

NAVIGALA — navigation locale dans le treillis (pas de sélection globale)

Intuition de la méthode

On n'évalue pas tous les concepts d'un coup. On explore le treillis comme un **arbre de décision** : depuis T , on ne descend que vers l'enfant dont l'intention est *encore* incluse dans l'instance, et on recommence. On s'arrête dès qu'aucun enfant ne convient ; la classe est décidée par vote sur l'extension du concept atteint. Si l'on ne bouge pas de T , c'est un échec explicite.



Différence nette avec GRAND : sur X_2 , GRAND vote silencieusement sur T ; NAVIGALA s'arrête à la racine et le signale — « je ne peux pas classer ».

Gestion de l'ambiguïté : **EXPOSER STRUCTURELLEMENT l'échec (arrêt = « ne sait pas »)**

Synthèse — complete lattice methods

Méthode	Critère de décision	$X_1 = \{a, c\}$	$X_2 = \{b, c\}$	Ambiguïté
GRAND	vote sur l'extension du concept le plus spécifique	$C_5 \rightarrow 1A/1B$ (non tranché)	repli $\top \rightarrow 2A/3B \rightarrow B$ (silencieux)	masquer
GALOIS	similarité intention / instance (k -plus-proches)	brut : $C_5 = C_2$; Jaccard : C_5 (mixte)	égalité stricte C_2/C_3	révéler
RULEARNER	1 ^{re} règle concept $\rightarrow$ classe satisfaite	aucune règle pure ; dépend du repli	égalité C_2/C_3 tranchée par l'ordre	trancher (ordre externe)
NAVIGALA	navigation enfant par enfant depuis $\top$	chemin unique $\rightarrow C_5$ (ambiguïté persiste)	arrêt à $\top$: échec explicite	exposer l'échec

Sur X_1 , aucune des quatre ne *résout* l'ambiguïté de C_5 ; elles diffèrent seulement par ce qu'elles en *disent*. Sur X_2 , seule NAVIGALA distingue « classé B » de « n'a pas pu être classé ».

Famille 2 — Sub-lattice methods

On n'utilise qu'un sous-treillis filtré : LEGAL, CIBLe/IGLUE, CLNN

LEGAL (1/2) — construire les hypothèses de la classe A

Principe. LEGAL apprend le concept « être de classe A ». Il ne garde du treillis que les concepts qui séparent bien A de B : ce sont les **hypothèses**.

	a	b	c	d	cl.
g_1	1	1	0	0	A
g_2	1	1	1	0	A
g_3	0	1	1	1	B
g_4	0	0	1	1	B
g_5	1	0	1	0	B

$$X^+ = \{g_1, g_2\} \quad X^- = \{g_3, g_4, g_5\}$$


Un concept (ext, int) est une **hypothèse** de A s'il est :

- **valide** : son extension couvre des positifs X^+ ;
- **quasi-cohérent** : son extension ne contient (quasi) aucun négatif X^- .

On teste les concepts du treillis :

- C_1 , ext $\{g_1, g_2\}$: 2 positifs, 0 négatif $\Rightarrow$ **retenu** $\rightarrow H_1 : \{a, b\} \Rightarrow A$
- C_2 , ext $\{g_2\}$: 1 positif, 0 négatif $\Rightarrow$ **retenu** $\rightarrow H_2 : \{a, b, c\} \Rightarrow A$
- C_5 , ext $\{g_2, g_5\}$: 1 positif mais $g_5 \in X^- \Rightarrow$ **rejeté** (pas quasi-cohérent)
- $\top$, ext $\{g_1..g_5\}$: 3 négatifs $\Rightarrow$ **rejeté**

Sous-treillis d'hypothèses de A : $\{H_1, H_2\}$. Le concept mixte C_5 en est exclu d'office.



LEGAL (2/2) — classer une instance : trois issues

Règle. On compte combien d'hypothèses de A l'instance X vérifie ($\text{int} \subseteq X$).

Trois issues possibles

- **Justification** : ≥ 1 hypothèse vérifiée $\rightarrow$ classé **A**.
- **Réfutation** : 0 hypothèse vérifiée $\rightarrow A$ rejeté $\rightarrow$ (binaire) classé **B**.
- **Silence** : signaux contradictoires $\rightarrow$ abstention.


Mécanisme à 3 issues d'après le tutoriel Mephu Nguifo (EGC'02) ; la survey n'en montre que le comptage binaire.

Sur le mini-dataset

$X_1 = \{a, c\}$: $H_1 \{a, b\} \subseteq \{a, c\}$? **non** (b) ; $H_2 \{a, b, c\} \subseteq \{a, c\}$? **non**.

$X_2 = \{b, c\}$: $H_1 \{a, b\} \subseteq \{b, c\}$? **non** (a) ; H_2 ? **non**.

$\Rightarrow$ 0/2 hypothèse vérifiée pour les deux.



Monotonie : si X vérifie $H_2 (\{a, b, c\})$, il vérifie forcément $H_1 (\{a, b\} \subseteq \{a, b, c\}) \Rightarrow$ on teste du plus général au plus spécifique, sans revisite.

Gestion de l'ambiguïté : **CENSURER par seuil — C_5 mixte ne franchit jamais la quasi-cohérence**

CIBLe / IGLUE (1/2) — redécrire les objets en vecteurs numériques

Idée. Sortir de la logique « inclus / pas inclus » : placer les objets dans un espace **numérique** où faire un k -NN.

1. Concepts pertinents. On garde les concepts dont l'extension est d'une seule classe (ils discriminent) :

$$\mathcal{P} = \{C_1, C_2, C_3, C_4\}.$$

C_5 (mixte, entropie maximale) est **écarté**.

2. Redescription. Pour un objet g et un attribut m :

$$\text{descripteur}(g, m) = \#\{C \in \mathcal{P} : g \in \text{ext}(C) \text{ et } m \in \text{int}(C)\}.$$


Redescription des 5 objets

	a	b	c	d	cl.
g_1	1	1	0	0	A
g_2	2	2	1	0	A
g_3	0	1	2	2	B
g_4	0	0	1	1	B
g_5	0	0	0	0	B

ex. $g_2 \in \text{ext}(C_1)$ et $\text{ext}(C_2)$; a est dans les deux intentions $\Rightarrow 2$.

g_5 n'est dans l'extension d'aucun concept pur $\Rightarrow$ vecteur nul : c'est le cas difficile (appariement partiel nécessaire).

CIBLe / IGLUE (2/2) — k -NN dans l'espace redécrit



A en haut à gauche (fort a, b), B en bas à droite (fort c, d),
 g_5 à l'origine.

Reste à exécuter : redécrire $X_1 = \{a, c\}$ et $X_2 = \{b, c\}$ puis lancer le k -NN — la redescription d'une *instance-test* est le point sous-spécifié de la littérature.

Gestion de l'ambiguïté : **DILUER dans une distance numérique — C_5 devient une position intermédiaire**

3. k -NN sur ces vecteurs (distance Manhattan / Euclidienne / Mahalanobis) :
une instance proche de $g_1, g_2 \Rightarrow A$; proche de $g_3, g_4 \Rightarrow B$.

4. **Prototypes dynamiques** : on ne garde comme voisins que les objets les plus informatifs.

IGLUE

appariement **complet** : l'instance doit être entièrement redécrite, sinon rejet.

CIBLe

appariement **partiel** p/q : tolère une redescription incomplète $\Rightarrow$ classe les instances de type g_5 qu'IGLUE rejette.

CLNN — 1-NN local à chaque nœud du sous-treillis

Principe. À chaque nœud (concept), un **1-NN** est entraîné sur l'extension du nœud. On classe l'instance avec le 1-NN du **nœud le plus spécifique qui la couvre**.

Objets en binaire sur (a, b, c, d) ; d_H = distance de Hamming. (Variante CLNB : 1-NN remplacé par un Bayes naïf — inutilisable ici, extensions trop petites.)

$$X_1 = \{a, c\} = (1, 0, 1, 0)$$

Nœud le plus spécifique tel que $\text{int} \subseteq X_1$: C_5 , extension $\{g_2, g_5\}$.

$$d_H(X_1, g_2) = (1, 1, 1, 0) = 1$$

$$d_H(X_1, g_5) = (1, 0, 1, 0) = 0$$

$\Rightarrow$ 1-NN = g_5 (classe B) $\Rightarrow$ **X_1 classé B.**

Le vote brut de GRAND sur $\{g_2, g_5\}$ donnait 1A/1B; le 1-NN tranche.

$$X_2 = \{b, c\} = (0, 1, 1, 0)$$

Aucun concept propre tel que $\text{int} \subseteq X_2 \Rightarrow$ nœud $\top$, extension $\{g_1, \dots, g_5\}$.

	g_1	g_2	g_3	g_4	g_5
$d_H(X_2, \cdot)$	2	1	1	2	2
classe	A	A	B	B	B

$\Rightarrow$ deux plus proches à distance 1 : g_2 (A) et g_3 (B) $\Rightarrow$ **égalité, le 1-NN ne tranche pas.**



Gestion de l'ambiguïté : **DÉLÉGUER** à un 1-NN local — résolue si la géométrie sépare (X_1) , sinon non (X_2)

Synthèse — sub-lattice methods

Méthode	Sous-treillis utilisé	Décision	Sur le mini-dataset	Ambiguïté
LEGAL	hypothèses valides + quasi-cohérentes	comptage à 3 issues (justif. / réfut. / silence)	$X_1, X_2 : 0/2$ hyp. $A \rightarrow$ réfutation $\rightarrow B$	censurer (seuil)
CIBLe IGLUE	/ concepts pertinents (entropie / Laplace)	k -NN sur descripteurs redécrits + prototypes	redescription à exécuter ; complet (IGLUE) vs partiel (CIBLe)	diluer (distance)
CLNN	sous-treillis complet, 1-NN local / nœud	1-NN du nœud le plus spécifique	$X_1 @ C_5 \rightarrow B$; $X_2 @ T$: égalité	déléguer (local)


Filtrer le treillis en amont (seuils de validité / cohérence) est déjà une réponse à l'ambiguïté : on écarte les concepts mixtes avant de classer. Prix à payer : perte d'information, forte dépendance aux seuils.

Famille 3 — Concept cover methods

Un jeu de concepts « couvre » les données ; classification par longueur d'encodage : MDL / Krimp

MDL / Krimp — tables de codes par classe (mécanisme)

Principe. Une table de codes par classe, construite **uniquement** à partir des données de cette classe ; on classe une instance dans la classe qui l'encode le plus court.



4^e famille de réponse à l'ambiguïté

Aucun motif mixte ne peut exister : CT_A n'est construite que sur les objets de A , CT_B que sur ceux de B . L'ambiguïté n'est pas gérée — elle est **structurellement empêchée**.


Gestion de l'ambiguïté : **EMPÊCHER STRUCTURELLEMENT — pas de concept inter-classes possible**

MDL / Krimp — exemple chiffré (1/2) : jeu h_1-h_8 et tables de codes

Reconstruction pédagogique — schéma d'encodage Krimp simplifié

Longueur de code d'un motif = $-\log_2(\text{usage}/\sum \text{usage})$; lissage de Laplace (code long, fixé à 4 bits) pour un singleton jamais utilisé à l'entraînement ; coût d'inscription d'un motif dans la table = son codage par la table standard. Jeu construit pour donner des longueurs entières.

Données			CT_A (sortie de Krimp)			CT_B (sortie de Krimp)		
	attributs	cl.	motif	usage	code	motif	usage	code
h_1	a b c	A	{a, b}	4	1	{d, e}	4	1
h_2	a b c	A	{c}	2	2	{c}	2	2
h_3	a b d	A	{d}	1	3	{a}	1	3
h_4	a b e	A	{e}	1	3	{b}	1	3
h_5	c d e	B	{a}, {b}	0	4	{d}, {e}	0	4
h_6	c d e	B						
h_7	a d e	B						
h_8	b d e	B						
			$\sum \text{usage} = 8$			$\sum \text{usage} = 8$		



Sur un jeu aussi petit, seul le motif le plus fréquent ({a, b} resp. {d, e}) « paie » son inscription dans la table.

MDL / Krimp — exemple chiffré (2/2) : classification de X_1 – X_4

Couverture = balayage de la table par longueur de motif décroissante ; $L(X \mid CT) =$ somme des codes des motifs utilisés.

Instance	couverture par CT_A	couverture par CT_B	$L(\cdot \mid CT_A)$	$L(\cdot \mid CT_B)$	décision
$X_1 = \{a, b, c\}$	$\{a, b\} + \{c\} = 1+2$	$\{c\} + \{a\} + \{b\} = 2+3+3$	3	8	A
$X_2 = \{c, d, e\}$	$\{c\} + \{d\} + \{e\} = 2+3+3$	$\{d, e\} + \{c\} = 1+2$	8	3	B
$X_3 = \{a, b, d, e\}$	$\{a, b\} + \{d\} + \{e\} = 1+3+3$	$\{d, e\} + \{a\} + \{b\} = 1+3+3$	7	7	égalité
$X_4 = \{c, d\}$	$\{c\} + \{d\} = 2+3$	$\{c\} + \{d\} = 2+4$	5	6	A (faux)

X_3 — l'ambiguïté ressort comme un score identique

Moitié motif A ($\{a, b\}$), moitié motif B ($\{d, e\}$) : $7 = 7$. MDL expose l'égalité au lieu de la masquer — mais ne la tranche pas.

X_4 — confiant et faux (analogue local du poisson)

d est le marqueur de B (4/4 objets B, 1/4 objets A), pourtant X_4 est classé A : dans CT_B , d est toujours absorbé par $\{d, e\}$ et n'a pas de code court isolé (4 bits, Laplace). Erreur **entièrement traçable** à la structure de la table.

Le score MDL est cohérent avec l'entraînement pour les quatre instances — et pourtant X_4 est classé à tort. Compresser $\neq$ discriminer.

MDL / Krimp — compression du nombre de concepts

Table 7 — nombre de concepts retenus par MDL comparé au treillis complet (10 des 20 jeux de données).

Dataset	Objets	Attributs	Concepts totaux	Concepts MDL	% retenu
auto	205	135	67 557	57	0,08 %
breast	699	16	642	24	3,7 %
car	1 728	25	12 617	94	0,7 %
chess	28 056	58	152 753	1 675	1,1 %
ecoli	336	29	694	25	3,6 %
iris	150	19	107	13	12,1 %
mushroom	8 124	90	181 945	211	0,1 %
nursery	12 960	30	176 536	392	0,2 %
wine	178	68	13 170	52	0,4 %
zoo	101	42	4 563	17	0,4 %

MDL ne conserve qu'une fraction infime des concepts (souvent $< 1\%$) : la table de codes est un résumé très compact de la classe. Cette compression agressive optimise la *description intra-classe* et non la *séparation inter-classes* — d'où un score comparable entre classes mais **non calibré**.

Synthèse — concept cover methods

Méthode	Mécanisme	Décision	Statut de l'exploration
MDL / Krimp	table de codes par classe, construction gloutonne (coût table + coût données)	classe = longueur d'encodage minimale de l'instance	mécanisme + exemple chiffré (h_1-h_8) + exemple survey (poisson)

Apport propre de la famille : en construisant chaque modèle de classe sur ses seules données, on rend l'ambiguïté inter-classes *impossible* plutôt que de la traiter. Contrepartie : un score non calibré, cohérent avec l'entraînement mais pas nécessairement juste.

Ce qu'il reste à faire

- **Méthodes ensemblistes** : BFC, BNC, FPS-FCA, DNC, RMCS, B-RCL (section 3 de la survey) — non abordées.
- **Méthodes distribuées** (section 4 de la survey) — non abordées.
- **Redescription CIBLe** calculée à la main sur le mini-dataset (mécanisme identifié, pas encore exécuté).
- Approfondissement autonome des mots-clés **CIBLe** / **CLNN** (et la variante CLNB).
- Relire **Sangroya et al.** avec la grille de lecture construite ici (positionnement exact dans la taxonomie).
- **Piste de recherche ouverte** : concevoir un critère de sélection de concepts orienté *discriminabilité inter-classes* plutôt que *compression intra-classe* (limite identifiée de MDL).