

Formal Concept Analysis pour expliquer des modèles de Deep Learning boîte noire

Étude de Sangroya et al. (2019) et reproduction expérimentale

Fokouo Luciano

École Nationale Supérieure Polytechnique de Yaoundé
Master 2 Data Science

24 août 2026

Plan de la présentation

- 1 L'article de Sangroya et al.
- 2 Reproduction expérimentale
- 3 Discussion critique

Partie 1 — L'article

Sangroya, Anantaram, Rawat, Rastogi (TCS Innovation Labs) — CEUR-WS Vol-2529, 2019

Constat des auteurs

Les systèmes de deep learning fonctionnent souvent comme des **boîtes noires** : aucune justification explicite n'accompagne la prédiction. Exemple donné : un diagnostic médical automatisé sans raison associée ne peut convaincre l'utilisateur.


Comment utiliser la Formal Concept Analysis, enrichie par une ontologie de domaine, pour expliquer la sortie d'un modèle de deep learning traité comme une boîte noire ?

Le cadrage introductif insiste sur le NLP comme motivation ; la validation expérimentale, elle, est entièrement tabulaire (diabète) — détail discuté en Partie 3.

Objectifs et contributions revendiquées

Deux contributions explicitement annoncées

- 1 Proposer une approche fondée sur la FCA pour générer des explications des sorties d'un modèle.
- 2 Montrer l'efficacité de cette méthode sur un jeu de données réel : la prédiction du diabète.



Mérite additionnel revendiqué : généralisable au-delà de la classification, si le problème est modélisable par un treillis FCA — affirmation, non démontrée dans l'article.

Concepts fondamentaux : FCA et ontologie

Formal Concept Analysis

- Contexte formel (G, M, I) : objets, attributs, relation binaire
- Concept formel $(A, B) : A' = B, B' = A \text{ — } A = \text{extension}, B = \text{intention}$
- Treillis de concepts $\mathcal{L}$: hiérarchie sous-concept/sur-concept
- Règle d'implication $S \Rightarrow T : S' \subseteq T'$

Ontologie de domaine

- Spécification formelle des concepts/rerelations d'un domaine
- Stockée en RDF (triplets sujet-prédicat-objet)
- Codée en OWL (Protégé)
- Ici : ontologie DIAB (diabète), BioPortal

Deux objets distincts à ne pas confondre : le treillis (calculé sur les données) et l'ontologie (connaissance externe).

Framework proposé (Fig. 1 de l'article)




Fig. 1: Overview of the Proposed Framework


Source : Sangroya et al. (2019), Fig. 1 — le treillis de concepts est le point de convergence entre données, sortie du modèle boîte noire et ontologie de domaine.

Algorithme 1(a) — PREDICT_FCA (pseudocode)

```
1: procedure PREDICT_FCA( $c_0, c_1, s_i$ )
2:    $P \leftarrow \emptyset$ 
3:    $s_i.lattice \leftarrow \text{LOAD\_FCA}(s_i)$ 
4:   for all  $(e_j, i_j) \in s_i.lattice$  do
5:     for all  $(e_k, i_k) \in c_0.lattice$  do
6:       if  $i_k \subseteq i_j$  then
7:          $P \leftarrow 0$ 
8:       end if
9:     end for
10:    for all  $(e_k, i_k) \in c_1.lattice$  do
11:      if  $i_k \subseteq i_j$  then
12:         $P \leftarrow 1$ 
13:      end if
14:    end for
15:  end for
16:  return  $P$ 
17: end procedure
```

Reproduction condensée, fidèle aux lignes 3–21 de l'Algorithme 1. Traduction schématique sur le slide suivant.

Classification FCA — représentation schématique




Traduction visuelle du pseudocode précédent : un treillis par valeur cible (diabète / non-diabète), comparaison par inclusion d'intentions.

Algorithme 1(b) — ExplanationGenerator (pseudocode)

```
1: procedure EXPLANATIONGENERATOR( $S, D$ )
2:    $P_{ML}, P_{FCA}, E \leftarrow \emptyset$ 
3:   for all  $s_i \in S$  do
4:      $p \leftarrow M.PREDICT(s_i)$ 
5:      $P_{ML}[i] \leftarrow \mathbf{1}[p > 0.5]$ 
6:      $P_{FCA}[i] \leftarrow PREDICT\_FCA(s_i)$ 
7:     for all  $f_j \in s_i$  do
8:        $f_j \leftarrow MODIFY(f_j)$ 
9:        $P \leftarrow PREDICT\_FCA(s_i)$ 
10:      if  $P_{ML}[i] = P_{FCA}[i]$  then
11:         $responsable \leftarrow (P \neq P_{ML}[i])$ 
12:      else
13:         $responsable \leftarrow (P = P_{ML}[i])$ 
14:      end if
15:    end for
16:  end for
17:  return  $E$ 
18: end procedure
```

Reproduction condensée, fidèle aux lignes 22–48. Point clé : $P_{ML}[i]$ est calculé une seule fois, jamais recalculé.
Traduction schématique sur le slide suivant.

Génération des explications — représentation schématique



Si $P_{ML} = P_{FCA}$ au départ

la feature est **responsable** si la modification *change* P_{FCA}

Si $P_{ML} \neq P_{FCA}$ au départ

la feature est **responsable** si la modification *aligne* P_{FCA} sur P_{ML}

Expérimentation des auteurs

- **Dataset** : Pima Indians Diabetes (Kaggle/UCI), variable cible Outcome
- **Prétraitement** : suppression des valeurs manquantes/invalides (non détaillé), enrichissement par ontologie (ranges, hiérarchie)
- **Modèle ML** : LSTM, classification binaire
- **Split** : 540 train / 150 test
- **Features** : « les 11 features disponibles » (texte de l'article)
- **Architecture LSTM** (couches, unités, dropout, optimiseur) : **non spécifiée par les auteurs**

Objectif explicite des auteurs : la FCA sert à expliquer le ML, pas à le concurrencer en performance.

Résultats des auteurs (Tableau 2 et 3)

Tableau 2 — Accuracy, Precision, Recall

Métrique	ML Model	FCA
Accuracy	70%	73%
Precision	77%	72%
Recall	63%	90%

Tableau 3 (importance des features) : **Blood Pressure** la plus influente pour la classe « diabète » (16.4%), **BMI** la plus influente pour « non-diabète » (45.3%), **Age** la moins influente (5.4%).

Conclusions et perspectives des auteurs


- FCA plus précise que le ML → hypothèse avancée : taille limitée du dataset
- Comparer les performances n'était **pas** l'objectif : l'objectif est d'expliquer le ML
- Approche revendiquée « model and domain agnostic », interprétation « sur une base théorique solide »
- Généralisation au multi-classe annoncée « facilement » — non démontrée
- Perspective future explicite : extension à la vision par ordinateur

L'article ne comporte pas de section « Limites » dédiée — très peu d'éléments auto-critiques (détail en Partie 3).

Partie 2 — Notre reproduction

Environnement local (VSCode) pour FCA/ontologie, Kaggle (CPU) pour le LSTM

Objectif de la reproduction



Deux environnements : local (VSCode) pour prétraitement, ontologie, FCA ; Kaggle (CPU) pour l'entraînement du LSTM.

Écart avec le papier

768 patients bruts, 8 variables. Le papier annonce $540+150 = 690$ échantillons. **Aucune combinaison** de suppression sur les colonnes à zéros invalides ne retombe sur 690 (le plus proche : 724).

Colonne	Zéros invalides
Glucose	5
BloodPressure	35
SkinThickness	227
Insulin	374
BMI	11

Stratégie retenue : suppression (Glucose/BP/BMI) → 724 lignes ; imputation médiane par classe (SkinThickness, Insulin).

Vérification de l'ontologie DIAB (rdflib)

Synonymes + hiérarchie : **présents** (classe D0ID_9352). Plages cliniques structurées (BP, BMI) : **absentes** de l'ontologie brute — définies manuellement, comme les auteurs l'indiquent avoir fait eux-mêmes (avis d'experts).

Feature	0	1	2
Glucose	< 140	140–199	$\geq$ 200
BloodPressure	< 70	70–100	> 100
BMI	< 23	23–27.5	> 27.5
Age	< 30	30–50	> 50
Autres (4)	tertiles empiriques		

Glucose_range n'atteint jamais 2 dans ce dataset — catégorie « morte » conservée par fidélité aux données.

Modèle LSTM (branche Kaggle)

Architecture non spécifiée par le papier — choix documentés

LSTM(32) → Dropout(0.2) → Dense(1, sigmoid) — binary_crossentropy, adam, EarlyStopping (patience 10) — reshape 3D ($n, 8, 1$), split 80/20 stratifié

Métrique	Papier (ML)	Notre LSTM (5-fold CV)
Accuracy	70%	75.5% ($\pm 5.2\%$)
Precision	77%	66.5% ($\pm 9.0\%$)
Recall	63%	62.3% ($\pm 8.5\%$)

Sur un split unique : 65.5%/50%/58% — forte variance sur ~ 145 patients de test, d'où le recours à la validation croisée.

Treillis construits (train set, bibliothèque concepts)

24 attributs binaires — treillis « non-diabète » : 4011 concepts (4010 non triviaux) — treillis « diabète » : 2993 concepts (2992 non triviaux)

Règle testée	Accuracy	Precision	Recall
Premier concept, priorité classe 1	34.5%	34.5%	100% (dégénéré)
Concept le plus spécifique (retenue)	78.6%	63.8%	88%
Papier (FCA)	73%	72%	90%

Le pseudocode et le texte (section 2.3) se contredisent sur la règle d'inclusion à appliquer — plusieurs règles testées empiriquement.

Reproduction de l'algorithme d'explication

Lecture clé du pseudocode

$P_{ML,i}$ calculé **une seule fois**, jamais recalculé → toute la boucle d'explication tourne en local sur la FCA, sans nouvel aller-retour Kaggle.

Feature	Non-Diabète	Diabète
BMI_range	100%	100%
BloodPressure_range	87.4%	66%
Glucose_range	87.4%	68%
Age_range, Pedigree, Insulin, Preg., Skin	73.7%	12%

MODIFY non spécifiée → test des 2 autres catégories de range. Tendance qualitative retrouvée (BP/BMI dominants, Age marginal) mais résultats bien plus tranchés que le papier (bimodal vs étalé 5–45%).

Résultats de la reproduction — synthèse

LSTM
(5-fold CV)



75.5% / 66.5%
/ 62.3%
(Acc/Prec/Rec)

FCA
(règle retenue)



78.6% / 63.8% / 88%
(Acc/Prec/Rec)

Même profil que le papier : FCA > LSTM en recall, FCA < LSTM en precision

Comparaison papier / reproduction

Métrique	Papier ML	Papier FCA	Notre LSTM	Notre FCA
Accuracy	70%	73%	75.5%	78.6%
Precision	77%	72%	66.5%	63.8%
Recall	63%	90%	62.3%	88%

- Recall FCA > Recall ML : retrouvé dans les deux cas
- Precision FCA < Precision ML : retrouvée dans les deux cas
- Profil général cohérent, valeurs absolues différentes
- Feature importance : tendance qualitative retrouvée, distribution plus polarisée

Partie 3 — Discussion

Éléments non spécifiés, limites, questions ouvertes, prochaines lectures

Éléments non spécifiés par le papier — adaptations nécessaires

- ① Prétraitement des valeurs manquantes (total 690 non reproductible)
- ② Plages cliniques (ranges) — non extractibles de l'ontologie DIAB brute
- ③ Architecture du LSTM — totalement non spécifiée
- ④ Mise en forme des données tabulaires pour le LSTM (reshape 3D)
- ⑤ Règle de classification PREDICT_FCA — pseudocode ambigu
- ⑥ Fonction MODIFY — non spécifiée

Six points où chaque reproduction doit faire ses propres choix, documentés section par section dans le rapport.

Limites mentionnées par les auteurs

Explicitement reconnues

- Dataset « pas très grand » — explication possible de la meilleure accuracy FCA
- Travail limité aux problèmes à deux classes

Perspectives annoncées (pas des limites)

- Généralisation au multi-classe « facile » — non démontrée
- Extension future à la vision par ordinateur

Pas de section « Limitations » dédiée dans cet article court.

Limites identifiées lors de la reproduction

Données & protocole

- Dataset restreint (~ 145 test) $\rightarrow$ forte variance (5–9 pts en CV)
- 78.6% vs 75.5% : pas de test statistique, pas de preuve de supériorité
- LSTM peu documenté ; pas de comparaison à XGBoost/RF/MLP
- Discrétisation : perte d'info, dépendance aux seuils
- Ontologie : ranges non extractibles, définis manuellement

Explication & généralisation

- Accord/désaccord FCA-ML $\neq$ preuve de fidélité au modèle
- P_{ML} figé : mesure la sensibilité de la FCA, pas celle du LSTM
- 31% de désaccord initial $\rightarrow$ presque toutes les features « responsables »
- Binaire, tabulaire, un seul dataset, un seul domaine

Questions ouvertes

- Généralisation réelle au multi-classe, à des données de plus grande dimension ?
- Applicabilité à des données non tabulaires (vision, texte) ?
- Ponts avec CNN, Vision Transformers, GNN ?
- Comparaison à des modèles tabulaires modernes (gradient boosting) ?
- Stabilité des concepts face aux seuils de discrétisation ?
- Comment évaluer, indépendamment, la fidélité d'une explication symbolique ?
- Intégration plus rigoureuse et traçable de l'ontologie ?
- Détection de prédictions atypiques via la FCA ?
- Que faire en cas de conflit entre connaissance de domaine et comportement du modèle ?

Objectifs pour les prochaines lectures

- FCA + XAI
- FCA + classification
- FCA + ontologies
- FCA + knowledge graphs
- FCA pour Deep Learning
- FCA pour données non tabulaires
- FCA + Computer Vision
- FCA + GNN
- Concept-based explanations
- Rule-based explanations
- Fidelity of explanations
- Symbolic explanations of black-box models
- Neuro-symbolic approaches
- Domain knowledge + XAI
- Reliability / trustworthiness + FCA

Chaque axe motivé, dans le rapport écrit, par un point précis laissé ouvert par Sangroya et al.

Ce que montre l'article

Une représentation FCA peut servir de représentation conceptuelle parallèle à un modèle ML, enrichie par une ontologie de domaine, pour comparer une prédiction symbolique à celle d'une boîte noire.

Ce que montre la reproduction

Les tendances générales sont confirmées, mais avec une forte dépendance à la représentation des données, à la discrétisation, à la règle de classification FCA retenue, et à des choix méthodologiques non spécifiés par l'article.

La question de la fidélité, de la robustesse et de la généralisation de cette représentation à des modèles et données plus complexes reste ouverte.